Predicción del tabaquismo y del consumo de alcohol mediante aprendizaje automático a partir de variables antropométricas y clínicas

Juan E. Agudelo Berrío, Jerónimo Betancur Álvarez, Juan M. Ocampo López

I. Introducción

El tabaquismo y el consumo de alcohol constituyen comportamientos de interés para la salud pública debido a su relación con diferentes alteraciones fisiológicas y enfermedades crónicas. La identificación de patrones asociados con estos hábitos puede contribuir al análisis de factores relacionados con el estilo de vida y al desarrollo de herramientas de apoyo para la investigación en salud. Sin embargo, la relación entre las características demográficas, las mediciones antropométricas y los indicadores bioquímicos puede ser compleja, lo que motiva la exploración de métodos computacionales capaces de modelar relaciones lineales y no lineales.

En este contexto, el aprendizaje automático (Machine Learning, ML) ofrece un conjunto de técnicas que permite construir modelos predictivos a partir de observaciones previas. Entre sus aplicaciones se encuentra la clasificación del estado de tabaquismo a partir de variables clínicas, así como la predicción de patrones de consumo de alcohol mediante datos demográficos y biológicos. Investigaciones recientes han evaluado modelos como los bosques aleatorios, las máquinas de vectores de soporte, los métodos de ensamble y las redes neuronales para abordar este tipo de problemas [1]–[4].

El presente proyecto propone desarrollar y evaluar modelos de aprendizaje automático para clasificar el estado de tabaquismo y el indicador de consumo de alcohol a partir de variables antropométricas y clínicas. Para ello, se empleará el conjunto de datos *Smoking and Drinking Dataset with Body Signal*, disponible en Kaggle, el cual contiene información demográfica, mediciones corporales, indicadores de salud y etiquetas asociadas con ambos comportamientos.

El trabajo se plantea como un problema de aprendizaje supervisado y contempla la comparación de diferentes modelos de clasificación, con el propósito de determinar su capacidad predictiva y analizar las características que aportan información relevante para las predicciones. La evaluación permitirá estudiar las ventajas y limitaciones de cada aproximación bajo una metodología experimental común. El objetivo no es establecer relaciones causales ni sustituir una valoración médica, sino estudiar el potencial predictivo de los datos disponibles.

II. Descripción del problema

II-A. Contexto y formulación del problema

El problema consiste en estimar el estado de tabaquismo y el indicador de consumo de alcohol de una persona a partir de sus características demográficas, antropométricas y clínicas. La utilidad de abordar esta tarea mediante aprendizaje automático radica en la posibilidad de integrar múltiples variables en un mismo sistema predictivo y comparar diferentes técnicas para identificar patrones que no necesariamente se describen mediante relaciones lineales simples.

El problema se estudiará mediante dos tareas de clasificación supervisada. La primera corresponde a la clasificación multiclase del estado de tabaquismo, utilizando la variable `SMK_stat_type_cd`. La segunda corresponde a la clasificación binaria del consumo de alcohol, utilizando la variable `DRK_YN`. Esta separación permite evaluar cada objetivo de forma independiente y comparar el desempeño de los modelos para ambos problemas.

II-B. Descripción del conjunto de datos

El conjunto de datos empleado es *Smoking and Drinking Dataset with Body Signal*, publicado en Kaggle y suministrado para el desarrollo del proyecto. El archivo `smoking_driking_dataset_Ver01.csv` contiene 991 346 registros y 24 columnas.

De las 24 columnas, 22 corresponden a características distintas de las etiquetas objetivo y dos representan los resultados que se desea predecir. Las características incluyen variables demográficas y antropométricas como sexo (`sex`), edad (`age`), estatura (`height`), peso (`weight`) y perímetro de cintura (`waistline`). También se incluyen mediciones de agudeza visual (`sight_left` y `sight_right`), indicadores de audición (`hear_left` y `hear_right`) y variables fisiológicas como presión arterial sistólica (`SBP`), presión arterial diastólica (`DBP`) y glucosa en sangre (`BLDS`).

Adicionalmente, el conjunto contiene indicadores bioquímicos: colesterol total (`tot_chole`), colesterol HDL (`HDL_chole`), colesterol LDL (`LDL_chole`), triglicéridos (`triglyceride`), hemoglobina (`hemoglobin`), proteína en orina (`urine_protein`), creatinina sérica (`serum_creatinine`), aspartato aminotransferasa (`SGOT_AST`), alanina aminotransferasa (`SGOT_ALT`) y gamma-glutamil transferasa (`gamma_GTP`).

La primera variable objetivo, `SMK_stat_type_cd`, codifica tres estados: 1 corresponde a personas que nunca han fumado, 2 a personas que fumaban anteriormente y dejaron de hacerlo, y 3 a personas que fuman actualmente. En el archivo analizado, estas categorías contienen 602 441, 174 951 y 213 954 registros, respectivamente. Por su parte, `DRK_YN`

indica si la persona consume alcohol, con los valores `Y` para sí y `N` para no. Se registran 495 488 observaciones positivas y 495 858 negativas.

Esta distribución muestra que el problema de tabaquismo presenta un desbalance entre sus tres clases, mientras que las clases del indicador de consumo de alcohol presentan frecuencias prácticamente iguales. Por ello, la evaluación del primer objetivo deberá considerar métricas que no dependan exclusivamente de la exactitud global, con el propósito de evaluar adecuadamente el desempeño en cada clase.

II-C. Calidad de los datos y codificación

La inspección inicial del archivo no identificó valores nulos explícitos en ninguna de las columnas. Por tanto, no se requiere aplicar imputación de valores faltantes en la versión inicial del conjunto de datos. No obstante, la ausencia de valores nulos no garantiza que todas las mediciones sean válidas. Se observan registros extremos, como un perímetro de cintura de 999 cm y un valor de `SGOT_AST` de 9999, que deben examinarse durante el control de calidad para determinar si corresponden a errores, códigos especiales o mediciones válidas.

Las variables deben tratarse según su naturaleza. El sexo es una variable nominal; los indicadores de audición contienen categorías codificadas como 1 (normal) y 2 (anormal), y la proteína en orina utiliza una escala ordinal de seis niveles. Las mediciones antropométricas y bioquímicas se tratarán como variables numéricas, después de verificar sus rangos y distribuciones. Las etiquetas de tabaquismo y consumo de alcohol se manejarán como variables objetivo categóricas, no como magnitudes continuas.

En consecuencia, el preprocesamiento incluirá la revisión de tipos de datos, la validación de rangos, la codificación apropiada de variables categóricas y, cuando corresponda, el escalamiento de las características numéricas. Si el análisis posterior confirma que ciertos valores extremos son inválidos, se definirán reglas documentadas para su tratamiento. Cualquier imputación o transformación que estime parámetros a partir de los datos se ajustará únicamente con el conjunto de entrenamiento, para evitar filtraciones de información hacia la evaluación.

II-D. Paradigma de aprendizaje seleccionado

La aproximación seleccionada es el aprendizaje supervisado, específicamente la clasificación multiclase para el estado de tabaquismo y la clasificación binaria para el consumo de alcohol. Esta elección se justifica porque el conjunto contiene etiquetas previamente registradas para ambos objetivos, lo que permite entrenar los modelos con ejemplos etiquetados y comparar sus predicciones con los valores observados.

Para estudiar el potencial predictivo de las características clínicas y antropométricas, se excluirán ambas columnas objetivo de la matriz de entrada en los dos problemas. De esta manera, el modelo de tabaquismo no utilizará directamente la etiqueta de consumo de alcohol y el modelo de consumo de alcohol no utilizará directamente la etiqueta de tabaquismo. Esta decisión permite concentrar el análisis en la información demográfica y fisiológica disponible.

La metodología experimental posterior comparará distintas familias de modelos supervisados, incluyendo métodos paramétricos, métodos no paramétricos, ensambles basados en árboles y redes neuronales. La selección final se basará en los resultados obtenidos mediante una estrategia de validación definida y en métricas adecuadas para cada tipo de clasificación.

III. Estado del arte

La aplicación de aprendizaje automático a la predicción de hábitos de consumo se ha estudiado mediante datos clínicos, biométricos y demográficos. Los trabajos revisados permiten identificar enfoques relevantes para la selección de modelos y la evaluación experimental.

Aishwarya et al. [1] estudiaron la predicción del estado de tabaquismo utilizando características clínicas y biométricas de una base de datos de Kaggle distinta de la empleada en este proyecto. A partir de una muestra equilibrada de 2 000 observaciones, compararon regresión logística, árboles de decisión, K vecinos más cercanos, bosques aleatorios, CatBoost y redes neuronales artificiales. Los autores utilizaron una partición de entrenamiento y prueba del 80 % y 20 %, respectivamente, y evaluaron diferentes estrategias de búsqueda de hiperparámetros. El bosque aleatorio alcanzó una exactitud de 0.80 y un F1 de 0.79, con valores de AUC entre 0.84 y 0.85 según la estrategia de búsqueda. El estudio también utilizó métodos de inteligencia artificial explicable, como SHAP y LIME, para estudiar la contribución de las características a las predicciones. Estos resultados muestran la utilidad potencial de los modelos basados en árboles para clasificar el tabaquismo a partir de datos clínicos.

Souza et al. [2] compararon modelos lineales y no lineales para distinguir fumadores de no fumadores a partir de 23 mediciones de química clínica. El conjunto final incluyó 188 observaciones equilibradas. Los autores compararon análisis discriminante por mínimos cuadrados parciales (PLS-DA), regresión logística, máquinas de vectores de soporte y bosques aleatorios. Se empleó una partición estratificada del 70 % para entrenamiento y del 30 % para prueba; además, se utilizaron validación cruzada para PLS-DA y validación *out-of-bag* para el bosque aleatorio. Este último obtuvo una exactitud de 85.6 % en la validación *out-of-bag* y de 80.4 % en el conjunto de prueba, con un coeficiente de correlación de Matthews de 0.612 en prueba. Aunque el tamaño de muestra es limitado, el trabajo respalda la evaluación de métodos no lineales sobre variables bioquímicas.

Leaks et al. [3] desarrollaron modelos para predecir el consumo moderado de alcohol frente a la abstinencia utilizando datos de la encuesta estadounidense NHANES. Su enfoque incluyó métodos de ensamble apilado y *gradient boosting*, combinando variables demográficas y bioquímicas. Los modelos alcanzaron un AUC de 0.929 durante la validación cruzada y de 0.806 en la validación reportada para el conjunto combinado de variables. Cuando se utilizaron únicamente variables bioquímicas, el AUC de validación fue de 0.757, mientras que con variables demográficas fue de 0.783.

Entre las características predictivas relevantes se identificaron gamma-glutamil transferasa, sexo, hierro y consumo de otras sustancias. Este estudio muestra la pertinencia de combinar información demográfica y clínica para predecir comportamientos asociados con el consumo de alcohol, aunque su definición de consumo moderado no es idéntica a la etiqueta binaria del presente proyecto.

Por su parte, Karakuş [4] estudió la predicción del consumo de alcohol mediante redes neuronales artificiales (ANN), redes neuronales convolucionales (CNN) y redes de memoria a largo y corto plazo (LSTM), utilizando un conjunto de datos con 991 346 registros y 24 atributos proveniente del sistema de seguro de salud de Corea. Este trabajo utiliza la misma base de datos que se usará para desarrollar este trabajo. Los autores aplicaron codificación de etiquetas, normalización min-max y una partición del 70 % para entrenamiento y 30 % para prueba. Evaluaron exactitud, precisión, sensibilidad y F1. La ANN obtuvo una exactitud de 0.7377 y un F1 de 0.7376, superando a CNN, con exactitud de 0.7124, y LSTM, con 0.6844. Estos resultados constituyen un punto de referencia para la tarea de consumo de alcohol, aunque no reemplazan una evaluación controlada de los modelos que se desarrollarán en este proyecto.

En conjunto, la literatura evidencia que tanto los modelos clásicos de aprendizaje automático como las redes neuronales pueden extraer patrones predictivos de variables clínicas y demográficas. Sin embargo, los resultados publicados no son directamente comparables cuando difieren el tamaño de muestra, la definición de las clases, las variables de entrada y la estrategia de validación. Por ello, el presente trabajo evaluará ambos objetivos bajo un diseño experimental común, documentando el preprocesamiento y comparando los modelos mediante métricas apropiadas para cada tarea.

Referencias

[1] S. Aishwarya, P. C. Siddalingaswamy, and K. Chadaga, "Explainable artificial intelligence driven insights into smoking prediction using machine learning and clinical parameters," *Scientific Reports*, vol. 15, p. 24069, 2025.

[2] M. de Oliveira Souza, P. R. Filgueiras, I. Wilson *et al.*, "Classifying smoking status using linear and non-linear models based on clinical health records," *Analytical and Bioanalytical Chemistry*, vol. 418, pp. 4891–4901, 2026.

[3] K. Leaks, T. M. Norden-Krichmar, and J. P. Brody, "Predicting moderate drinking behaviors in national health and nutrition examination survey participants using biochemical and demographical factors with machine learning," *Alcohol*, vol. 113, pp. 1–10, 2023.

[4] Y. Karakuş, "Alcohol user prediction with deep learning methods from electronic health record data," *Harran University Journal of Engineering*, vol. 10, no. 2, pp. 94–104, 2025.